


WEAVIATE — AI-NATIVE

- Khối duy nhất (Go), Module System.
- Mỗi Shard chứa **3 lưu trữ song song**.
- Object Store (LSM) + HNSW + Inverted Index.
- Modules: vectorizer, generative, reranker.



- 1 container duy nhất.
- Tối ưu RAM: ~250 MB.
- Phù hợp tích hợp RAG trực tiếp.

NATIVE HYBRID SEARCH

- **Vector:** Hiểu ngữ nghĩa, sót exact keyword.
- **BM25:** Exact match, sót paraphrase.
- **Hybrid:** **Kết hợp cả hai** trong 1 API.
- **Inverted Index + HNSW** chung một shard.



- **BM25F:** Trọng số trường (title $\times 2$, body $\times 1$).
- **Fusion:** RSF (mặc định) hoặc RRF.

FUSION MATHEMATICS

- RRF (Reciprocal Rank Fusion).

$$\text{RRF_score}(d) = \sum_i \frac{1}{(k + \text{rank}_i(d))}, \quad k=60$$


- Dùng thứ hạng thay vì điểm số gốc.
- Ổn định, không phụ thuộc scale điểm.

Doc	Rank Vec	Rank BM25	RRF Score
A	1	5	0.0318
B	3	2	0.0321
C	2	8	0.0308

■ Kết quả: doc_B thắng nhờ cân bằng tín hiệu.

MILVUS — DISTRIBUTED

- **Microservices tách biệt 4 tầng.**
- **Access:** Proxy (stateless).
- **Coordinator:** Root, Data, Query.
- **Worker:** Query, Data, Index Node.



- **Storage:** etcd, MinIO, Message Queue.
- **Yêu cầu 3+ containers.**
- **RAM tĩnh: ~398 MB.**


SCALE PER-ROLE

Tiêu chí	Qdrant / Weaviate	Milvus
Mô hình	Monolithic	Microservices
Tự mở rộng	Theo chiều dọc	Ngang từng tầng
Nghẽn cổ chai	Phải scale cả cụm	Chỉ thêm Node cần thiết
Quy mô	< 50 triệu vector	Hàng tỷ vector



- **Knowhere:** Động cơ cốt lõi (C++).
- Gói Faiss, HNSWlib, DiskANN.
- Tự động chọn tập lệnh SIMD.
- Tăng tốc index/search qua GPU CUDA.

MILVUS LIFECYCLE



Bước đo thực tế	Thời gian
insert (1K chunks)	~2805 ms
flush (ghi MinIO)	~2530 ms
load (vào RAM)	~343 ms
search (ANN)	~6.88 ms
Tổng chi phí	~5678 ms

- ✓ Tìm kiếm khả dụng ngay trên Growing Segment (Brute-force).
- ✗ Quan niệm “phải flush mới search được” là sai.
- ! Tránh flush liên tục dữ liệu nhỏ gây phân mảnh.

HIGH AVAILABILITY

Tiêu chí	Qdrant	Weaviate	Milvus
Sao chép	Shard replica	Multi-tenancy	Segment replica
Quản lý	Trong process	Trong process	Active-standby
Siêu dữ liệu	Trong process	Trong process	etcd Raft
Ứng dụng	Startup	Mid-scale	Enterprise

- **etcd quorum**: Chịu lỗi $(n-1)/2$ node.
- Coordinator tự động failover từ etcd.
- Segment sao chép chéo nhiều Query Node.

ARCHITECTURE COMPARISON

Tiêu chí	Qdrant	Weaviate	Milvus
Kiến trúc	Monolithic	Monolithic	Microservices
Lọc	Trong đồ thị	Allowlist	Dạng expr
Hybrid	Dense+Sparse	BM25F gốc	Xuyên mô hình
RAM nền	~79 MB	~250 MB	~398 MB
Tối ưu	Tốc độ	Tích hợp	Quy mô



Qdrant: Nhanh nhất
(Rust + In-graph).



Weaviate: Tự nhiên nhất
(BM25F chung shard).



Milvus: Khổng lồ nhất
(Microservices).

VECTOR QUANTIZATION

Kỹ thuật	Cơ chế	RAM ↓	Đánh đổi
Scalar (SQ)	f32 → u8	~4x	Recall giảm nhẹ
Product (PQ)	Cụm centroid	8-64x	Cần rescore
Binary (BQ)	Vector → bits	~32x	Tốc độ +40x

Hỗ trợ	SQ	PQ	BQ
Qdrant	Có	Có	Có
Weaviate	Không	Có	Có
Milvus	Có	Không	Không

- **Qdrant** cung cấp hệ sinh thái đầy đủ nhất.

FAIRNESS PROTOCOL

- HNSW: $M=16$, $ef_c=128$, $ef_s=64$, COSINE.
- Dữ liệu: 10K chunks tổng hợp, seed=42.
- Ground-Truth: Exact chunk-ID match.
- Đo lường 4 trụ cột: Latency, Recall, Tradeoff, DX.

- Full-stack: React + FastAPI + Docker.
- 3 cơ sở dữ liệu chạy song song.
- Embedding: Ollama nomic-embed-text (768-dim).
- Quy tắc: Không hardcode tham số.